



Prueba Técnica Data Scientist

Objetivo

El Challenge pone a prueba tus conocimientos en:

- Procesamiento y análisis de grandes volúmenes de datos.
- Uso de estadísticas y de Machine learning aplicados a problemas de ciberseguridad.
- Pensamiento crítico y diseño de soluciones prácticas.
- Comunicación clara de resultados.

Tu desafío

Problema 1: User Entity Behavior Analytics (UEBA)

El archivo `user_logins.csv` contiene un conjunto de datos de actividades de inicio de sesión. Se solicita desarrollar un sistema de detección de anomalías que permita identificar inicios de sesión sospechosos en los usuarios, mediante dos enfoques distintos:

A. Análisis estadístico y etiquetado:

- Realice un análisis exploratorio de los datos para identificar patrones de comportamiento de los usuarios.
- Defina reglas de normalidad que se adapten al comportamiento de cada usuario y use las reglas creadas para identificar los inicios de sesión normales y anómalos. Incorpore esa etiqueta binaria al set de datos.
- Utilizando llamadas por API a un modelo de lenguaje (GPT, Deepseek, Gemini u otro que elija), genere reportes sobre al menos tres usuarios que considere relevantes según el análisis realizado.

B. Modelo por Machine Learning:

- Proponga y entrene un modelo de machine learning adecuado para los datos y considerando las etiquetas generadas por el modelo A.
- Discuta problemáticas y estrategias que utilizaría para datasets con desbalance de datos.
- Proponga y calcule métricas relevantes para evaluar el desempeño del modelo. Justifique su elección.



Problema 2: Análisis de Vulnerabilidades con Web Scraping

El sitio `cvedetails` (<https://www.cvedetails.com>) publica información detallada sobre vulnerabilidades de seguridad (CVEs) de forma pública y accesible. Cada registro incluye datos como el identificador CVE, fecha de publicación, score de severidad (CVSS), tipo de vulnerabilidad, vendor y producto afectado.

- Scrapee los CVEs publicados en los últimos 3 meses desde `cvedetails.com`. Extraiga al menos los siguientes campos: CVE ID, fecha de publicación, CVSS score, tipo de vulnerabilidad, vendor y producto afectado.
- Use los datos scrapeados para crear al menos dos visualizaciones distintas en Looker Studio. Explique por qué eligió esas visualizaciones y qué insights de seguridad se pueden obtener de ellas. Justifique las decisiones tomadas sobre el manejo de datos.

✓ Entregables

Repo de github:

- Código comentado y estructurado. Visualizaciones realizadas.
- Tu entendimiento del problema y las decisiones tomadas.
- Explicación de la metodología y posibles mejoras a futuro.

Link de tablero en Looker

¡Buena suerte! 🚀